



AI Tuyển Sinh - Hybrid cho mùa cao điểm

Nguyễn Tiến Đạt_2A202600218

Thách thức mùa cao điểm

Vấn đề gặp phải

- Traffic tăng vọt 20x so với bình thường
- Hotline quá tải, không thể xử lý kịp
- Nhu cầu hỗ trợ 24/7 tăng cao
- Thiếu nhân lực đáp ứng nhanh


Giải pháp đề xuất

Chatbot RAG thông minh hoạt động 24/7, xử lý đồng thời hàng ngàn yêu cầu với độ chính xác cao.

Tích hợp hệ thống hiện có, tự động hóa 80% các câu hỏi thường gặp.

Kiến trúc Hybrid

Kết hợp sức mạnh điện toán đám mây với bảo mật nội bộ



1

Cloud Layer

Claude LLM, Vector DB, Semantic cache, Auto-scaling

2

API Gateway

Phân phối request, routing thông minh, load balancing

3

On-Prem Layer

CRM, SIS, PII dữ liệu nhạy cảm không ra ngoài

Chi phí triển khai MVP

\$11.4K

Mô hình tối ưu

Chi phí hàng năm thấp nhất với
semantic caching

\$19.2K

Mô hình đầy đủ

Chi phí hàng năm với đầy đủ tính năng

55-60%

Token LLM peak

Chiếm phần lớn chi phí - cần tối ưu ngay

3 chiến lược tối ưu chi phí



Semantic Cache

Giảm 40-60% token usage bằng caching thông minh theo ngữ nghĩa



Model Routing 3 tầng

Phân lớp request tự động, giảm 30-40% chi phí bằng việc chọn model phù hợp



Prompt Caching

Cache prompt templates, giảm 90% chi phí cho các câu hỏi lặp lại

Fallback Strategy 5 tầng

Đảm bảo trải nghiệm người dùng mượt mà trong mọi tình huống

01

Semantic Cache

Trả kết quả đã cache nếu có

02

Haiku Model

Model nhẹ, nhanh, chi phí thấp

03

GPT-4o-mini

Cân bằng giữa chất lượng và chi phí

04

Rule-based Logic

Xử lý theo quy tắc có sẵn

05

Chuyển human

Hỗ trợ bởi người thật

Tác động tổng thể



Giảm chi phí LLM

Kết hợp 5 tầng fallback và 3 chiến lược tối ưu giúp giảm **55-65%** chi phí LLM so với mô hình cơ bản.

ROI nhanh

Hoàn vốn trong vòng 4-6 tháng nhờ giảm chi phí vận hành và tăng hiệu suất.

Lợi ích chính



Tốc độ cao

Phản hồi dưới 2 giây cho 95% request, xử lý 500+ concurrent users



Co giãn tốt

Auto-scale cloud resources theo traffic, handle 20x peak load



Bảo mật tuyệt đối

PII dữ liệu nhạy cảm never leaves on-prem servers



Tích hợp mượt

Connect với CRM, SIS hiện có thông qua API

Tổng kết

Kiến trúc Hybrid

Kết hợp cloud và on-prem để cân bằng giữa sức mạnh và bảo mật

Tối ưu 55-65%

Giảm chi phí LLM đáng kể nhờ 3 chiến lược và 5 tầng fallback

Sẵn sàng triển khai

MVP có thể triển khai trong 6-8 tuần với ROI trong 4-6 tháng

