

Scenario 3: University Admissions & Student Support Agent

Tên nhóm: Nhóm 5 Ngày: 2026-04-22

08:00–08:15 | Khởi động & Mini Reflection

Mỗi người viết 3 ý → Tổng hợp nhóm:

- 1. Nhóm nắm tốt RAG pipeline cơ bản và prompt engineering — đã từng build chatbot FAQ
- 2. Còn yếu về ước lượng cost production và thiết kế hệ thống chịu tải cao
- 3. Chưa có kinh nghiệm xử lý traffic đột biến mùa tuyển sinh
- 4. Muốn đi sâu vào deployment thực tế, cost optimization và reliability
- 5. Cần hiểu rõ hơn về compliance dữ liệu cá nhân (NĐ 13/2023)

08:15–08:40 | Worksheet 0 — Learning Timeline

1. 2–3 kỹ năng nhóm tự tin nhất

#	Kỹ năng	Mô tả ngắn
1	Thiết kế RAG pipeline	Kết hợp document retrieval với LLM để trả lời FAQ tuyển sinh chính xác
2	Prompt engineering & system prompt	Viết instruction rõ ràng, kiểm soát tone/persona cho AI agent
3	API integration & tool use	Gọi API tra cứu điểm, nộp hồ sơ, kiểm tra lịch thi qua function calling

2. Mô tả ngắn sản phẩm/scenario

AI Assistant tư vấn tuyển sinh & hỗ trợ tân sinh viên, triển khai trên web. Sử dụng RAG trên kho FAQ tuyển sinh, quy chế đào tạo và biểu mẫu. Có khả năng tra cứu hồ sơ cá nhân có

kiểm soát và escalate sang cán bộ khi vượt phạm vi. Ngôn ngữ chính là tiếng Việt có dấu, không dấu và teencode (tiếng anh sẽ được phát triển khi có một lượng sinh viên quốc tế nhất định).

3 nhóm user: - **Thí sinh & phụ huynh:** điểm chuẩn, ngành học, học phí, hạn nộp hồ sơ - **Sinh viên năm nhất:** đăng ký học phần, ký túc xá, lịch nhập học - **Cán bộ tuyển sinh:** dashboard câu hỏi phổ biến, duyệt câu trả lời nhạy cảm.

3. Chủ đề xuyên suốt cả ngày

“Làm sao deploy AI tuyển sinh đủ tin cậy, đủ rẻ, đủ nhanh trong mùa cao điểm?”

4. Trả lời 3 câu hỏi bắt buộc

Câu hỏi	Trả lời
Sản phẩm giải quyết bài toán gì?	Giảm tải hotline mùa tuyển sinh, cung cấp thông tin nhất quán 24/7, cập nhật nhanh theo từng đợt xét tuyển
Ai là người dùng chính?	Thí sinh & phụ huynh (hàng chục nghìn/ mùa peak), sinh viên năm nhất, cán bộ tuyển sinh
Vì sao phù hợp phân tích deployment & cost?	Traffic biến thiên cực mạnh theo mùa → bài toán scaling. Dữ liệu 2 tầng (public + PII) → tranh luận Cloud vs Hybrid. Cost LLM nhân trực tiếp với request → spike cost dễ tính. Accuracy sống còn → buộc human-in-the-loop

08:40–09:25 | Worksheet 1 — Enterprise Deployment Clinic

1. Bối cảnh tổ chức/khách hàng

- Trường đại học công/tư, quy mô ~10.000 sinh viên
- Phòng CNTT nội bộ nhỏ (~5-10 người), ngân sách IT trung bình
- Hệ thống hiện có: cổng thông tin sinh viên (SIS), CRM tuyển sinh, website WordPress, email/hotline
- Phòng ban liên quan: Phòng Tuyển sinh (nội dung), Phòng Đào tạo (quy chế), Phòng CNTT (hạ tầng)

2. Dữ liệu hệ thống đưng đến

Loại dữ liệu	Ví dụ	Nơi lưu trữ
Public — FAQ & quy định	Điểm chuẩn, học phí, chỉ tiêu, quy chế, biểu mẫu	Website, CMS
Internal — Hồ sơ ứng viên	Họ tên, CCCD, điểm thi, nguyện vọng	CRM tuyển sinh (on-prem)
Internal — Học tập sinh viên	Kết quả học tập, đăng ký học phần	SIS (on-prem)
Conversational logs	Lịch sử chat, câu hỏi phổ biến	Hệ thống AI (cloud)

3. Đánh giá mức độ nhạy cảm của dữ liệu: TRUNG BÌNH

Yếu tố	Đánh giá
Loại PII	Họ tên, CCCD, điểm thi, nguyện vọng — nhạy cảm nhưng không phải y tế/tài chính
Quy định áp dụng	Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân
Rủi ro nếu lộ	Ảnh hưởng uy tín trường, phạt hành chính, kiện tụng
Audit trail	CÓ — ai truy vấn hồ sơ nào, lúc nào, từ IP nào

4. Ba ràng buộc enterprise lớn nhất

#	Ràng buộc	Tác động nếu không xử lý
1	Traffic tăng 10-20x mùa tuyển sinh (tăng	Hệ thống treo → thí sinh không tra được thông tin → khiếu nại, uy tín giảm

lên 30-50x ngay giờ
công bố điểm chuẩn)

- | | | |
|---|---|---|
| 2 | Nội dung thay đổi theo từng đợt — điểm chuẩn, chỉ tiêu, quy chế cập nhật 3-5 lần/năm | AI trả lời thông tin cũ → sai thông tin → ảnh hưởng việc đăng kí, thi cử của thí sinh |
| 3 | Phản hồi phải nhanh và chính xác — sai deadline/thủ tục → thí sinh bị ảnh hưởng | Thí sinh hay cross-check điểm chuẩn trên web chính thức, nhưng deadline/thủ tục rườm rà thường sẽ hướng dẫn của chatbot |

5. Chọn mô hình triển khai: HYBRID (Cloud + On-prem)

6. Hai lý do

Lý do 1 — Chi phí cho mùa thi cử: Burst traffic chỉ xảy ra vài tuần/năm. Mua on-prem đủ mùa cao điểm → 90% thời gian còn lãng phí. Cloud autoscale trả tiền vào lúc dùng, phù hợp với workload biến thiên mạnh.

Lý do 2 — Giảm rủi ro compliance: Hồ sơ thí sinh (CCCD, điểm, nguyện vọng) đang nằm sẵn trong CRM/SIS nội bộ. Giữ nguyên vị trí + chỉ expose qua Lookup API có kiểm soát (trả field được phép, không expose raw data) → giảm thiểu rủi ro theo ND 13/2023.

Kiến trúc 2 tầng:

Tầng	Thành phần	Ghi chú
Cloud (biến thiên)	API Gateway + LB, LLM inference (Claude API), Vector DB cho FAQ public (Qdrant), Semantic cache (Redis), Monitoring (Grafana/Datadog)	Biến thiên theo peak
On-prem (có sẵn)	CRM tuyển sinh, SIS (kết quả học tập), Audit log, Lookup API nội bộ	Ràng buộc hiện có, không phải lựa chọn thiết kế

Lưu ý: Lookup API nội bộ (kết nối cloud ↔ on-prem) cần phòng IT build và maintain — tính vào cost vận hành.

Gợi ý thảo luận (trả lời nhanh)

Câu hỏi	Trả lời
Cần audit trail không?	CÓ — log ai hỏi gì về hồ sơ, lúc nào, từ đâu
Dữ liệu có được rời tổ chức không?	FAQ public: CÓ · Hồ sơ thí sinh: KHÔNG
Cần tích hợp hệ thống cũ không?	CÓ — CRM tuyển sinh, SIS, cổng thông tin sinh viên
Trả lời sai thì ai bị ảnh hưởng đầu tiên?	Thí sinh (mất cơ hội nhập học) → Nhà trường (uy tín, kiện tụng)

09:35–10:15 | Worksheet 2 — Cost Anatomy Lab

1. Ước lượng traffic

Chỉ số	Off-peak (~46 tuần)	Peak (~6 tuần)
User/ngày	~1.000	~8.000–10.000
Request/ngày	~3.000	~30.000–40.000 0
Turns/session (TB)	2-3	3-5
Peak concurrent	~10	~100-200

2. Ước lượng token/request

Phần	Token
System prompt	~400 (viết gọn từ đầu)

RAG context (top-3 chunks × 300 tokens)	~900
Câu hỏi user	~100
Input tổng	~1.400
Output	~300

Không tính lịch sử multi-turn vào baseline vì phần lớn câu hỏi mùa tuyển sinh là single-turn.

3. Các lớp cost (MVP/năm)

Nhóm	Hạng mục	USD/năm
Kỹ thuật	LLM API tokens	\$2.500–3.500
	Embedding + Vector DB	\$700–1.200
	Compute (API server, autoscale)	\$1.000–1.800
	Storage	\$700–1.200
	Logging + Monitoring	\$700–1.300
	Subtotal kỹ thuật	~\$4.900–7.700
Vận hành	Human review	\$1.500–3.000
	Maintenance (cập nhật content/prompt, reindex, eval)	\$3.500–5.500
	Lookup API build & maintain	\$1.500–3.000
	Subtotal vận hành	~\$6.500–11.500
	TỔNG/NĂM	~\$11.400–19.200

4. Cost sơ bộ ở mức MVP

Trung bình ~\$950–1.600/tháng. Tương đương ~25-40 triệu VNĐ/tháng — hợp lý so với lương 2-3 cán bộ tuyển sinh full-time.

5. Khi scale 5x/10x — phần nào tăng mạnh nhất?

Kịch bản	Token cost	Compute	Storage	Human review
5x users	+500%	+200%	+50%	+300%
10x users	+1000%	+400%	+100%	+500%

Token/API cost tăng tuyến tính, trở thành cost driver #1 khi scale. → Human review cost tăng nhanh nếu accuracy chưa cao.

Câu hỏi bắt buộc

Câu hỏi	Trả lời
Cost driver lớn nhất?	Token LLM mùa peak (~55-60% inference cost tập trung vào 6 tuần)
Hidden cost dễ quên?	Reindex embedding mỗi đợt (3-5 lần/năm), human review câu nhạy cảm, staging/testing env (+15-20% infra), rule-based fallback maintain theo đợt
Chỗ nào ước lượng quá lạc quan?	Turns/session có thể bị ước thấp (thí sinh lo lắng hỏi 8-15 turns thay vì 3). Nhiều nhóm quên tính cán bộ QA vào cost

Sanity check vs benchmark thị trường

Benchmark	Nguồn tham khảo	So sánh
Chatbot FAQ đại học (US, ~15k SV)	Case study Drift/Intercom edu sector	\$18k–25k/năm all-in (cao hơn với ước tính \$11.400–19.200 của nhóm)

Chatbot tuyển sinh ĐH FPT (VN, ước tính)	Báo cáo công khai + job posting	~\$15k–20k/năm (giá cả cũng gần với nhóm)
Kết luận	Ước tính của nhóm nằm trong dải hợp lý, đã tính phần cho Human review, lookup API maintain.	

10:15–10:50 | Worksheet 3 — Cost Optimization Debate

Các chiến lược được chọn

Chiến lược 1: Semantic Caching — LÀM NGAY (MVP v1.0)

Mục	Nội dung
Tiết kiệm phần nào	Token cost và latency — cắt 40-60% LLM call trong peak (hit rate ~50-70% cho FAQ lặp). Off-peak thấp hơn (~20-30%)
Lợi ích	Giảm cost token · Latency ~200ms từ cache vs 2-3s từ LLM · Giảm tải provider · Tăng throughput
Trade-off	Cache stale khi content vừa cập nhật → cần invalidation mechanism theo đợt · Cần tuning ngưỡng similarity
Thời điểm	Ngay từ MVP v1.0 — câu hỏi tuyển sinh lặp lại cực nhiều
Tool/stack	Redis + embedding similarity cosine ≥ 0.92 , TTL theo đợt

VD: “điểm chuẩn ngành CNTT năm nay?” khớp semantic với “ngành CNTT lấy bao điểm?” → một LLM call phục vụ tất cả variants.

Chiến lược 2: Model Routing / Tiering — LÀM NGAY (MVP v1.1)

Mục	Nội dung
-----	----------

Tiết kiệm phần nào	~30-40% cost token (so với baseline tất cả dùng Sonnet)
Lợi ích	Cost giảm mạnh · Latency fast path giảm · Model lớn không bị lãng phí cho câu trivial
Trade-off	Cần build classifier/router · Rủi ro route sai (câu phức tạp bị model yếu trả lời) → cần eval liên tục
Thời điểm	MVP v1.1 — sau khi có log đủ để calibrate router

Routing 3 tầng:

Tầng	Loại câu hỏi (tỉ lệ)	Xử lý	Cost
● Tier 1 — 60-70% request FAQ đơn giản		Vector search top-1 → template response, không cần LLM	~\$0
● Tier 2 — 25-30% Tư vấn thông thường		Claude Haiku 3.5 + RAG	\$0.8/1M input
● Tier 3 — 5-10% Câu nhạy cảm/phức tạp		Claude Sonnet 4.6 + Human Review	\$3/1M input + nhân sự

Chiến lược 3: Prompt Compression + RAG Context Optimization — ⌚ Phase 2

Mục	Nội dung
Tiết kiệm phần nào	20-30% input token

Lợi ích	Giảm cost mà không ảnh hưởng chất lượng nếu làm đúng · Giảm latency
Trade-off	Prompt quá ngắn có thể làm giảm accuracy. Giảm chunks retrieved có thể thiếu context. Cần A/B test kỹ
Thời điểm	System prompt gọn: MVP. RAG tuning (giảm 5→3 chunks + reranker): Phase 2 — cần data đánh giá trước → Ngưỡng bắt đầu Prompt Compression: cần ít nhất 500 request production có label chất lượng (thumbs up/down hoặc human eval) để A/B test đảm bảo accuracy không bị ảnh hưởng khi giảm context.

Chiến lược 4: Anthropic Prompt Caching (API-side) — **LÀM NGAY (MVP v1.0)**

Mục	Nội dung
Tiết kiệm phần nào	Giảm ~90% input token cost cho phần system prompt + RAG context được cache
Tiết kiệm phần nào	Giảm ~90% input token cost cho phần system prompt + RAG context được cache
Lợi ích	System prompt (~400 tokens) lặp lại mỗi request → cache hit từ turn thứ 2 trở đi. Đặc biệt hiệu quả trong session multi-turn. Cost cache read = 10% so với full input
Trade-off	Cache TTL 5 phút → phù hợp với session chat liên tục; cần thiết kế prompt structure để phần stable (system prompt, top FAQ context) đứng đầu, phần dynamic (câu hỏi user) đứng sau
Thời điểm	MVP v1.0 — bật ngay khi integrate Claude API, chi phí implement gần như bằng 0
Tool/stack	Anthropic cache_control: {"type": "ephemeral"} trên system prompt và static RAG blocks
<i>Low-hanging fruit: với ~1.400 input tokens/request và 40.000 request/ngày peak, caching system prompt 400 tokens tiết kiệm ~\$4-6/ngày peak — không lớn nhưng free effort.</i>	

Chiến lược 5: Batch API cho Async Workload — **Phase 2**

Mục	Nội dung
Tiết kiệm phần nào	50% cost so với sync API (Anthropic Batch API pricing)
Lợi ích	Phù hợp workload không cần real-time: kiểm tra trạng thái hồ sơ phức tạp, tổng hợp câu hỏi phổ biến cuối ngày, pre-generate câu trả lời cho top-200 FAQ trước ngày D
Trade-off	Kết quả trả sau tối đa 24h → chỉ dùng cho async use case, không thay thế sync path
Thời điểm	Phase 2 — sau khi phân loại rõ request nào có thể async

Chốt ưu tiên

Chiến lược	Tiết kiệm ước tính	Làm ngay?
Semantic Caching	40-60% LLM call peak	✅ MVP v1.0
Anthropic Prompt Caching (API-side)	~90% cost phần system prompt	✅ MVP v1.0
Model Routing	~30-40% cost token	✅ MVP v1.1
Prompt Compression	20-30% input token	⌚ Phase 2
Batch API (async workload)	50% cost request async	⌚ Phase 2

Kết hợp các chiến lược → ước tính giảm 55-65% tổng cost LLM so với baseline không tối ưu.

Lưu ý: các % không cộng dồn tuyến tính — request đã cache thì không cần routing. Con số 55-65% là ước tính tổng hợp.

10:50–11:25 | Worksheet 4 — Scaling & Reliability Tabletop

Tình huống 1: Traffic tăng đột biến

Bối cảnh: Ngày công bố điểm chuẩn, traffic tăng từ 3.000 → 40.000+ request/ngày trong vài giờ.

Chi tiết

Tác động tới user	App chat lag/timeout, thí sinh retry → tăng load thêm, call center ngập
Phản ứng ngắn hạn	Rate limit per IP · Trả cache/static ngay + thông báo “câu trả lời chi tiết sẽ có trong 2 phút” · Banner dẫn link bảng điểm chuẩn tñh
Giải pháp dài hạn	K8s HPA autoscale · Pre-warm cache top-200 câu hỏi trước ngày D · Load test (k6/Locust) trước mỗi mùa

Tình huống 2: LLM Provider timeout/outage

Bối cảnh: Claude API trả về timeout 100% trong 15 phút giữa mùa peak.

Chi tiết

Tác động tới user	Bot không trả lời hoặc báo lỗi → mất tin tưởng
Phản ứng ngắn hạn	Circuit breaker sau 5 timeout → chuyển sang 1 provider fallback duy nhất (Claude → GPT-4o-mini). Retry exponential backoff: 2 lần (1s, 2s) rồi kích hoạt fallback
Giải pháp dài hạn	Rule-based intent matcher cho top-50 FAQ + degraded mode UI rõ ràng (“Đang hoạt động chế độ hạn chế”). Không setup 3 provider vì maintain prompt cho nhiều provider = cost ẩn lớn

Tình huống 3: Response chậm >5s

Bối cảnh: P95 latency tăng từ 2s lên 8s do RAG retrieval chậm hoặc LLM overloaded.

Chi tiết

Tác động tới user	Thí sinh nghĩ bot đơ, refresh liên tục → vòng lặp xấu
--------------------------	---

Phản ứng ngắn hạn Streaming SSE (user thấy chữ trong ~500ms) · Hard timeout 5s → trả link FAQ tĩnh

Giải pháp dài hạn Vector DB read replica mùa peak · Reranker nhỏ hơn · Precompute embedding cho hot docs

Phân loại request

Loại	Ví dụ	Xử lý
Real-time cần	FAQ lookup, kiểm tra deadline, thông tin học phí	Sync, streaming
Async có thể	Kiểm tra trạng thái hồ sơ phức tạp, câu cần tra cứu DB sinh viên	Queue, trả kết quả sau


Metric cần monitor

Metric	SLO Target	Alert threshold
p95 latency — Cached FAQ	< 500ms	> 800ms
p95 latency — FAQ + Haiku	< 2s	> 3s
p95 latency — Tư vấn Sonnet	< 5s	> 7s
LLM API error rate	< 0.5%	> 1%
Cache hit rate (peak)	> 50%	< 30%
Human escalation rate	< 10%	> 20%
Silent failure rate	< 1%	> 2%

Silent failure detection: LLM trả lời sai nội dung mà không có HTTP error là điểm yếu cố hữu của chatbot.
Cách phát hiện:

- 1. **Confidence scoring:** Nếu RAG retrieval score < 0.75 → gắn cờ “low confidence” → log + tăng ưu tiên human review
- 2. **Consistency check:** Với top-50 câu FAQ quan trọng (điểm chuẩn, học phí, deadline) → chạy eval tự động hàng ngày so với ground truth
- 3. **User signal:** Tỷ lệ user hỏi lại cùng intent trong cùng session > 2 lần → flag là potential wrong answer
- 4. **Keyword guardrail:** Regex monitor output cho số điểm chuẩn, học phí, ngày tháng — nếu lệch khỏi range hợp lý → auto-hold + route Tier 3

Fallback proposal (5 tầng)



11:25–11:45 | Worksheet 5 — Skills Map & Track Direction

1. Tự chấm điểm năng lực (Thang điểm 1-5)

Thành viên	Business/Product	Infra/Data/Ops	AI Engineering/Application
Nông Trung Kiên	5	4	3

Trần Ngọc Huy	4	4	4
Bùi Thế Công	4	4	5
Nghĩa	4	4	5
Tiến	2	5	4
Sơn	3	5	5
Trung bình nhóm	3.8	4.3	4.3

2. Điểm mạnh nhóm

- **Mạnh nhất:** Cả AI Engineering và Infra/Data/Ops — 4.3/5
- **Yếu nhất:** Business/Product — 3.8/5
- **Phân tích:** Nhóm có thể build prototype nhanh và chất lượng tốt, nhưng cần bổ sung kỹ năng về Business/Production

3. Track Phase 2: AI Application Track

Lý do phù hợp với Scenario 3: - Chưa có prototype → build trước, scale sau là ưu tiên số 1 (Application > Productization). Chọn Productization khi đã có working product cần hardening; nhóm chưa đến giai đoạn đó. - Điểm Infra/Ops (4.3/5) ngang với AI Engineer/Application (4.3/5) → Application Track tận dụng thế mạnh, tránh rủi ro Productization Track yêu cầu Kubernetes/CI/CD thành thục - Scenario thiên về user journey, cần mở rộng đa kênh: **web** (kênh chính của thí sinh & phụ huynh VN) - Cần evaluation pipeline đặc thù domain tuyển sinh (accuracy là sống còn) — đây là Application-layer concern

Tại sao không chọn Productization Track dù Infra/Ops = 4.3? Productization yêu cầu hệ thống đang chạy production cần monitoring/CD/reliability hardening. Nhóm chưa có hệ thống để productize. Sẽ xem xét lại sau khi prototype hoàn thiện (Phase 3).

Deliverables Phase 2: 1. Prototype RAG chatbot với đánh giá RAGAS (faithfulness, answer relevancy) 2. Multi-channel adapter (web) 3. Admin dashboard (cán bộ tuyển sinh xem top câu hỏi, duyệt câu nhạy cảm) 4. Eval set 200 câu test domain tuyển sinh

4. 2–3 kỹ năng cần bù

#	Kỹ năng cần bù	Mảng	Cách học
1	Evaluation framework RAG (Ragas, TRULENS) — đo faithfulness, answer relevancy	AI Eng/App	DeepLearning.AI course “Building and Evaluating RAG”
2	LLM Observability (Langfuse) — tracing, cost dashboard, phát hiện câu trả lời sai	Infra/Ops	Langfuse docs + self-host trên Docker
3	NĐ 13/2023 về bảo vệ dữ liệu cá nhân — hiểu quy định để thiết kế đúng	Business/Product	Đọc nghị định + tham khảo case study

Team Note Sheet (tổng hợp)

Mục	Nội dung
Tên nhóm	Nhóm 5
Chủ đề	Scenario 3 — University Admissions & Student Support Agent
3 ràng buộc enterprise	(1) Traffic 10-20x mùa tuyển sinh · (2) Nội dung thay đổi theo đợt 3-5 lần/năm · (3) Phản hồi nhanh & chính xác (sai = thí sinh mất cơ hội)
Cost driver lớn nhất	Token LLM mùa peak (~55-60% inference cost tập trung 6 tuần) + Human review câu nhạy cảm

3 chiến lược optimize	(1) Semantic caching — MVP v1.0 · (2) Model routing 3 tầng — MVP v1.1 · (3) Prompt compression — Phase 2
Fallback/reliability plan	Cache → Haiku → GPT-4o-mini → Rule-based KB top-50 → Static FAQ + Human queue
Track Phase 2	AI Application Track (đa kênh + evaluation pipeline)

References

Tổng hợp các tài liệu tham khảo sử dụng để đối chiếu số liệu, thiết kế kiến trúc và lựa chọn chiến lược trong worksheet.

R1 — Compliance & Pháp lý

#	Tài liệu	Nguồn	Dùng ở đâu
R1.1	Nghị định 13/2023/NĐ-CP về bảo vệ dữ liệu cá nhân — hiệu lực 01/07/2023	thuvienphapluat.vn	Worksheet 1 (PII Protection), Kiến trúc Hybrid, Slide 3 & 4
R1.2	Hướng dẫn ND 13/2023 — phân loại dữ liệu cá nhân cơ bản vs nhạy cảm, nghĩa vụ kiểm soát dữ liệu, yêu cầu audit trail	Bộ Công an	Thiết kế on-prem layer, Audit Log Service

Điểm mấu chốt từ ND 13/2023 ảnh hưởng đến thiết kế: - Điều 9: Dữ liệu cá nhân nhạy cảm (thông tin định danh cá nhân, kết quả học tập) yêu cầu sự đồng ý rõ ràng - Điều 21–23: Bên kiểm soát dữ liệu phải duy trì hồ sơ xử lý dữ liệu — cơ sở thiết kế Audit Log - Điều 26: Chuyển dữ liệu cá nhân ra nước ngoài bị giới hạn — cơ sở cho quyết định **không đưa PII lên cloud nước ngoài**

R2 — LLM Pricing & Model Selection

#	Tài liệu	Nguồn	Dùng ở đâu
R2.1	Anthropic API Pricing (tháng 04/2026) — Claude Haiku 3.5: \$0.8/\$4 per MTok input/output; Claude Sonnet	claude.com/pricing	Worksheet 2 Cost Anatomy, Worksheet 3 Model Routing

#	Tài liệu	Nguồn	Dùng ở đâu
R2.2	4.6: \$3/\$15 per MTok OpenAI API Pricing — GPT-4o-mini: \$0.15/\$0.60 per MTok input/output	platform.openai.com/pricing	Fallback provider cost estimate, Worksheet 4
R2.3	Artificial Analysis — LLM Benchmark (price/performance tradeoffs, tokens/sec, latency)	artificialanalysis.ai	Lý do chọn Haiku cho Tier 1–2, Sonnet cho Tier 3

Số liệu đối chiếu (Model Routing 3 tầng):

Tier	Model	Input cost	Output cost	Ghi chú
Tier 1 (FAQ)	Vector search (no LLM)	~\$0	~\$0	Template response
Tier 2 (Tư vấn)	Claude Haiku 3.5	\$0.8/MTok	\$4/MTok	Fast, cheap
Tier 3 (Nhảy cảm)	Claude Sonnet 4.6	\$3/MTok	\$15/MTok	High quality
Fallback	GPT-4o-mini	\$0.15/MTok	\$0.60/MTok	Multi-provider redundancy

R3 — Prompt Caching

#	Tài liệu	Nguồn	Dùng ở đâu
R3.1	Anthropic: Prompt Caching — giảm tới 90% cost và 85% latency cho long prompts	claude.com/blog/prompt-caching	Worksheet 3 Chiến lược 4
R3.2	Anthropic Docs: Prompt Caching Technical Details — TTL 5 phút (default) / 1 giờ (extended), pricing multiplier: cache write 1.25x, cache read 0.1x base	platform.claude.com/docs	Cost calculation, thiết kế cache_control

Số liệu cụ thể (đối chiếu Worksheet 3 — Chiến lược 4):

Loại	Giá (Sonnet 4.6)	So với base input
Cache Write (5 phút)	\$3.75/MTok	1.25×
Cache Write (1 giờ)	\$6.00/MTok	2.0×
Cache Read	\$0.30/MTok	0.1× (tiết kiệm 90%)

- Minimum tokens để cache: Sonnet 4.6 = **2.048 tokens** → system prompt ~400 tokens chưa đủ, cần kết hợp static RAG context
- Tối đa **4 cache breakpoints** mỗi request
- Lưu ý thiết kế: phần stable (system prompt + static FAQ context) phải đứng đầu prompt

R4 — Semantic Caching

#	Tài liệu	Nguồn	Dùng ở đâu
R4.1	Redis: What is Semantic Caching — cache hits trả lời nhanh hơn 2–4×, optimal case 50–100×; thêm chỉ 5–20ms overhead; giảm LLM API cost ≥50%	redis.io/blog/what-is-semantic-caching	Worksheet 3 Chiến lược 1, Slide 6
R4.2	GPTCache — open-source semantic cache library, hỗ trợ nhiều similarity backend (FAISS, Milvus, Redis)	github.com/zilliztech/GPTCache	Stack đề xuất trong Worksheet 3

Số liệu đối chiếu (Semantic Caching): - Cache hit → 2–100× nhanh hơn so với gọi LLM trực tiếp (1–5 giây) - Real-world: chatbot trên tài liệu IRS trả kết quả **nhANH HƠN 15×** sau khi bật semantic cache - Similarity threshold điển hình: **cosine ≥ 0.85–0.95** (nhóm chọn 0.92 — conservative để tránh false hit) - Teams thực tế cắt được **≥50% LLM API cost** nhờ semantic caching

R5 — RAG & Evaluation

#	Tài liệu	Nguồn	Dùng ở đâu
R5.1	RAGAS: Automated Evaluation of Retrieval Augmented Generation (Shahul Es et al., 2023) — framework đánh giá RAG không cần ground truth	arxiv.org/abs/2309.15217	Worksheet 5 Track Phase 2, Deliverables

#	Tài liệu	Nguồn	Dùng ở đâu
	annotation, metrics: faithfulness, answer relevancy, context precision, context recall		
R5.2	LangChain RAG Tutorial — chunking strategy, embedding, retrieval pipeline	python.langchain.com/docs/tutorial/s/rag	Thiết kế RAG pipeline, chunk size 300 tokens
R5.3	DeepLearning.AI : Building and Evaluating Advanced RAG — kỹ năng cần bù (Worksheet 5)	deeplearning.ai	Kế hoạch học Worksheet 5

RAGAS metrics áp dụng cho AdmitMate:

Metric	Ý nghĩa	Tại sao quan trọng
Faithfulness	Câu trả lời có trung thực với context retrieved không?	Tránh hallucinate điểm chuẩn, học phí
Answer Relevancy	Câu trả lời có đúng với câu hỏi không?	Đảm bảo không lạc đề
Context Precision	Context retrieved có liên quan không?	Tối ưu chunk retrieval
Context Recall	Context retrieved có đủ thông tin không?	Đảm bảo không thiếu dữ liệu

R6 — Observability & Monitoring

#	Tài liệu	Nguồn	Dùng ở đâu
R6.1	Langfuse — open-source LLM observability platform, tracing toàn bộ LLM calls + RAG retrieval + embeddings, cost tracking per user, self-hostable	langfuse.com/docs	Worksheet 5 kỹ năng cần bù, Monitoring layer
R6.2	OpenTelemetry for LLM — chuẩn observability, Langfuse built on top	opentelemetry.io	Thiết kế vendor-neutral monitoring

R7 — Business Case & Benchmark ngành

#	Tài liệu	Nguồn	Dùng ở đâu
R7.1	Zendesk: AI Customer Service Statistics — 80% inquiries có thể giải quyết không cần human agent (CEO Zendesk, 2024)	zendesk.com/blog/ai-customer-service-statistics	Cơ sở mục tiêu giảm 60% call center volume
R7.2	Intercom / Drift Education Sector Case Studies — chatbot FAQ tại trường đại học Mỹ ~15k SV: \$18k–\$25k/năm all-in	Internal benchmark tổng hợp từ vendor case studies	Sanity check cost ước tính Worksheet 2
R7.3	EDUCAUSE 2024 Annual Survey — AI adoption in higher education: chatbot, automation, student support	edUCAUSE.edu	Bối cảnh thị trường, xu hướng triển khai

Đối chiếu Business Case: - 80% câu hỏi có thể AI xử lý tự động → cơ sở thực tế cho mục tiêu **60% giảm call center** (conservative estimate) - Benchmark trường US 15k SV: \$18–25k/năm → ước tính nhóm \$24–38k/năm hợp lý (cao hơn do PII overhead + Lookup API)

R8 — Infrastructure & Scaling

#	Tài liệu	Nguồn	Dùng ở đâu
R8.1	Kubernetes HPA (Horizontal Pod Autoscaler) — autoscale dựa trên CPU/memory/custom metrics	kubernetes.io/docs/tasks/run-application/horizontal-pod-autoscale	Worksheet 4 Tính hướng 1 (burst traffic)
R8.2	Qdrant Vector Database — open-source, self-hostable, hỗ trợ cosine similarity, filtering	qdrant.tech/documentation	Vector DB layer trong kiến trúc Hybrid
R8.3	Redis Stack — kết hợp caching +	redis.io/docs	Semantic Cache layer

#	Tài liệu	Nguồn	Dùng ở đâu
R8.4	vector search cho semantic cache k6 Load Testing — stress test trước mùa peak	k6.io/docs	Worksheet 4 giải pháp dài hạn